

Previsão e mapeamento de furtos e roubos de veículos

Alexnsadro Lazzaretti¹, Jeferson Solforoso Pompermaier², Murilo Gemi De Carli¹

¹Universidade Federal da Fronteira Sul (UFFS)

Abstract. *Public security in urban centers faces significant challenges, with vehicle thefts and robberies being offenses of high socio-economic impact. Despite the growing availability of open criminal data, there is a lack of integrated tools that transform these raw records into actionable intelligence. To mitigate this problem, this article describes the planning and development of a technological solution comprising a Machine Learning pipeline and an dashboard. The project, developed within the scope of the Project Planning and Management course at the Federal University of Fronteira Sul (UFFS), aims to predict and spatially map crime hotspots for vehicle offenses. The applied methodology encompassed data collection and preprocessing, the training of predictive models to identify spatio-temporal patterns, and integration with geoprocessing techniques. As a result, a visual and dynamic platform was structured, facilitating the understanding of criminal incidence, strategically assisting the preventive allocation of police resources, and supporting evidence-based decision-making.*

Resumo. *A segurança pública em centros urbanos enfrenta desafios significativos, sendo os furtos e roubos de veículos infrações de alto impacto socioeconômico. Apesar da crescente disponibilidade de dados criminais abertos, há uma carência de ferramentas integradas que transformem esses registros brutos em inteligência acionável. Para mitigar esse problema, este artigo descreve o planejamento e o desenvolvimento de uma solução tecnológica composta por um pipeline de Machine Learning e um dashboard. O projeto, desenvolvido no contexto da disciplina de Planejamento e Gestão de Projetos da Universidade Federal da Fronteira Sul (UFFS), tem como objetivo prever e mapear espacialmente manchas criminais (hotspots) de delitos veiculares. A metodologia aplicada abrangeu a coleta e o pré-processamento de dados, o treinamento de modelos preditivos para identificação de padrões espaço-temporais e a integração com técnicas de geoprocessamento. Como resultado, estruturou-se uma plataforma visual e dinâmica que facilita a compreensão da incidência criminal, auxiliando estrategicamente a alocação preventiva de recursos policiais e apoiando a tomada de decisão baseada em evidências.*

1. Introdução

A segurança pública representa um dos desafios mais complexos da gestão dos centros urbanos contemporâneos. Entre as ocorrências de natureza patrimonial, os furtos e roubos de veículos produzem impactos econômicos relevantes e afetam diretamente a percepção de segurança da população. Paralelamente, a digitalização dos serviços públicos ampliou a disponibilidade de registros criminais, como Boletins de Ocorrência (BOs), criando condições para o uso de métodos computacionais capazes de explorar padrões espaciais e temporais nesses dados.

Pesquisas anteriores demonstram que a análise espacial e os métodos preditivos podem contribuir para a identificação de áreas com maior concentração de ocorrências. Chainey, Tompson e Uhlig [2] avaliaram diferentes técnicas de mapeamento de *hotspots* e mostraram que dados históricos podem ser utilizados para estimar padrões espaciais futuros de criminalidade. Perry *et al.* [9] sistematizaram o conceito de policiamento preditivo como o uso de técnicas analíticas, especialmente quantitativas, para apoiar a identificação de alvos prováveis de intervenção policial, destacando que tais métodos devem atuar como suporte à decisão e não como substitutos da estratégia operacional. Em estudo experimental, Mohler *et al.* [3] observaram que previsões espaço-temporais dinâmicas podem auxiliar o direcionamento do patrulhamento. No contexto brasileiro, Alves, Ribeiro e Rodrigues [1] empregaram técnicas de aprendizado estatístico para investigar a relação entre indicadores urbanos e criminalidade, evidenciando o potencial de algoritmos de *Machine Learning* na análise desse domínio.

Esses trabalhos indicam que a utilidade prática de modelos preditivos depende não apenas do algoritmo empregado, mas também da organização dos dados, da representação espacial e da forma como os resultados são apresentados aos usuários. Nesse contexto, este artigo documenta o planejamento e o desenvolvimento de uma solução integrada composta por um *pipeline* de *Machine Learning* e um *dashboard*, com o objetivo de prever e mapear espacialmente a incidência de furtos e roubos de veículos. A proposta busca transformar registros criminais abertos em informações visualmente interpretáveis, permitindo a análise de áreas de maior risco e oferecendo suporte à tomada de decisão em segurança pública.

2. Definição do Problema

Apesar da crescente política de dados abertos e da disponibilidade de bases de dados sobre criminalidade, os órgãos de segurança pública e a sociedade civil frequentemente carecem de soluções tecnológicas integradas que transformem dados brutos em inteligência acionável. A leitura de planilhas extensas ou relatórios estáticos dificulta a identificação rápida de áreas de risco e a formulação de estratégias preventivas.

Diante desse contexto, o problema de pesquisa que norteia este projeto é: **Como planejar e estruturar um *pipeline* de *Machine Learning* capaz de prever ocorrências de furtos e roubos de veículos e, de forma integrada, apresentar essas informações em um *dashboard* de mapeamento espacial para otimizar a tomada de decisão em segurança pública.**

3. Objetivos

3.1. Objetivo Geral

Desenvolver e gerenciar a implementação de um *pipeline* completo de *Machine Learning* integrado a um *dashboard*, focado na predição e no mapeamento espacial (manchas criminais) de furtos e roubos de veículos, consolidando as práticas de planejamento de projetos.

3.2. Objetivos Específicos

Para garantir o alcance do objetivo geral, as entregas do projeto foram divididas nos seguintes objetivos específicos:

- Realizar a extração, o tratamento e a análise exploratória de bases de dados criminais, estruturando-as para o consumo de algoritmos preditivos;
- Desenvolver e treinar modelos de *Machine Learning* capazes de identificar padrões temporais e espaciais associados à ocorrência de roubos e furtos;
- Aplicar técnicas de geoprocessamento para a geração de manchas criminais (*hotspots*);
- Construir e implantar um *dashboard* que permita a visualização amigável dos dados históricos, das previsões do modelo e do mapa de risco;
- Aplicar metodologias de Planejamento e Gestão de Projetos para garantir o escopo, o cronograma e a qualidade das entregas da solução.

4. Justificativa

A justificativa para a realização deste projeto sustenta-se tanto em seu impacto social quanto em sua relevância acadêmica e tecnológica. Do ponto de vista social e da gestão pública, a criação de um mapeamento preditivo de manchas criminais fornece uma ferramenta baseada em evidências para auxiliar estrategicamente o patrulhamento preventivo, com o potencial de reduzir o tempo de resposta policial e inibir novas ocorrências. A democratização do acesso a esses dados, apresentados de forma visual e intuitiva no *dashboard*, também empodera a sociedade civil no entendimento da segurança local.

No âmbito acadêmico e técnico, o projeto demonstra a aplicação prática dos conceitos estudados na disciplina de Planejamento e Gestão de Projetos da Universidade Federal da Fronteira Sul (UFFS). Ele ilustra o ciclo de vida completo de um produto de software orientado a dados, unindo a engenharia de dados, a modelagem preditiva e a construção de interfaces de usuário, evidenciando como a gestão eficiente do projeto é essencial para integrar essas diferentes áreas da computação em uma solução funcional e de alto valor agregado.

5. Fundamentação Teórica

A fundamentação teórica deste trabalho articula conceitos de análise criminal, policiamento preditivo, análise espacial e aprendizado de máquina. Esses elementos fornecem a base conceitual para a construção do *pipeline* analítico e para a interpretação dos resultados produzidos pelo sistema.

5.1. Análise criminal e policiamento preditivo

A análise criminal utiliza dados de ocorrências para identificar padrões, tendências e concentrações que possam apoiar ações de prevenção e planejamento. Quando técnicas estatísticas e computacionais são utilizadas para estimar onde ou quando determinados eventos podem ocorrer, essa abordagem se aproxima do conceito de policiamento preditivo. Perry *et al.* [9] definem o policiamento preditivo como a aplicação de técnicas analíticas, particularmente quantitativas, para identificar possíveis alvos de intervenção policial a partir de previsões estatísticas.

Essa abordagem não implica prever com certeza a ocorrência de um crime individual. O objetivo é estimar probabilidades e padrões de risco a partir de dados históricos e contextuais, oferecendo informação adicional para apoiar decisões operacionais. Assim, a qualidade dos dados, a escolha das variáveis e a interpretação dos resultados são aspectos centrais, pois previsões computacionais devem ser entendidas como instrumentos de apoio, e não como decisões autônomas [9].

5.2. Análise espacial e manchas criminais

Crimes não se distribuem de maneira uniforme no espaço urbano. Determinadas regiões podem apresentar concentrações recorrentes de ocorrências, formando as chamadas manchas criminais ou *hotspots*. O mapeamento dessas áreas permite representar geograficamente a intensidade dos eventos e comparar regiões com diferentes níveis de incidência.

Chainey, Tompson e Uhlig [2] compararam diferentes técnicas de identificação de *hotspots*, como mapas de pontos, mapas temáticos, grades e estimativa de densidade por kernel, demonstrando que o mapeamento de concentrações históricas pode possuir capacidade preditiva sobre a distribuição espacial de ocorrências futuras. Dessa forma, a análise espacial constitui uma etapa importante na transformação de registros georreferenciados em unidades adequadas à modelagem computacional.

Neste projeto, essa necessidade é tratada por meio da discretização do espaço em células hexagonais utilizando o sistema H3. O H3 é um sistema hierárquico de indexação geoespacial que particiona o território em células hexagonais e permite converter coordenadas de latitude e longitude em identificadores espaciais discretos [6]. Essa representação facilita a agregação de ocorrências e a criação de variáveis tabulares utilizadas pelo modelo preditivo.

5.3. Aprendizado de máquina aplicado à predição criminal

O Aprendizado de Máquina permite construir modelos capazes de identificar relações entre variáveis a partir de exemplos observados e utilizar essas relações para realizar classificações ou estimativas em novos dados. Em problemas de criminalidade, atributos espaciais, temporais e socioeconômicos podem ser combinados para estimar níveis de risco ou a probabilidade de ocorrência de determinados delitos.

Alves, Ribeiro e Rodrigues [1] demonstraram o uso de técnicas de aprendizado estatístico na previsão de criminalidade a partir de métricas urbanas, ressaltando a capacidade de algoritmos baseados em conjuntos de modelos de lidar com relações não lineares e correlações entre variáveis. No presente trabalho, o *Random Forest* foi adotado como modelo de *baseline*. Proposto por Breiman [4], o método combina diversas árvores de decisão construídas com amostras e subconjuntos aleatórios de atributos, agregando suas previsões para melhorar a capacidade de generalização e reduzir a sensibilidade de uma única árvore às variações dos dados.

5.4. Avaliação em dados desbalanceados

A previsão de ocorrências criminais pode gerar um problema de classificação desbalanceada, pois, em um determinado intervalo temporal, a quantidade de regiões sem registro de crime tende a ser muito superior à quantidade de regiões com ocorrências. Nesse cenário, a acurácia isolada pode produzir uma percepção inadequada de desempenho, uma vez que um classificador pode obter alto valor simplesmente favorecendo a classe majoritária.

Por essa razão, métricas que consideram o desempenho sobre a classe positiva são particularmente relevantes. O *F1-Score* combina precisão e revocação em uma única medida, enquanto a área sob a curva ROC (ROC-AUC) avalia a capacidade de discriminação do classificador em diferentes limiares. Entretanto, Saito e Rehmsmeier [5] mostram que a interpretação da curva ROC requer cautela em bases fortemente desbalanceadas e

que medidas baseadas em precisão e revocação podem fornecer uma visão mais informativa do desempenho prático. Essa discussão fundamenta o uso de múltiplas métricas na avaliação do *baseline* deste projeto.

5.5. Visualização e apoio à decisão

A etapa final de uma solução analítica consiste em transformar as saídas do modelo em informação compreensível. No contexto da segurança pública, a apresentação espacial dos resultados permite relacionar previsões a regiões concretas do território e facilita a identificação de áreas prioritárias. Perry *et al.* [9] destacam que previsões somente produzem efeitos operacionais quando integradas a processos de decisão e a estratégias de atuação. Por esse motivo, o projeto associa o *pipeline* de predição a um *dashboard* voltado à exploração dos dados históricos e das estimativas de risco.

6. Trabalhos Relacionados

Diferentes pesquisas já exploraram a combinação entre dados criminais, análise espacial e métodos preditivos. Chainey, Tompson e Uhlig [2] investigaram a capacidade de técnicas de mapeamento de *hotspots* em antecipar a distribuição espacial de crimes e verificaram desempenho superior da estimativa de densidade por kernel em relação a outras formas de representação avaliadas no estudo. O trabalho estabelece uma referência importante para a utilização de padrões históricos na identificação de áreas com maior probabilidade de novas ocorrências.

Mohler *et al.* [3] avançaram nessa direção ao avaliar, por meio de ensaios de campo controlados, um modelo espaço-temporal de policiamento preditivo. Os autores compararam previsões algorítmicas com previsões produzidas por analistas e observaram evidências de redução de ocorrências associada ao patrulhamento orientado pelo modelo em determinados cenários, reforçando o potencial de previsões dinâmicas para apoiar a alocação de recursos.

No Brasil, Alves, Ribeiro e Rodrigues [1] aplicaram algoritmos de aprendizado estatístico a indicadores urbanos para investigar sua relação com a criminalidade em cidades brasileiras. Embora o foco do estudo seja distinto do presente projeto, seus resultados demonstram que técnicas de *Machine Learning* podem extrair relações relevantes de bases urbanas complexas e contribuir para análises voltadas a políticas públicas.

O presente trabalho diferencia-se por concentrar-se especificamente em furtos e roubos de veículos e por integrar, em um único fluxo, aquisição e tratamento de dados abertos, discretização geoespacial, classificação preditiva e visualização em *dashboard*. Assim, o objetivo não é apenas avaliar um algoritmo isolado, mas estruturar um artefato computacional completo capaz de transformar registros históricos em uma representação espacial de risco utilizável como apoio à decisão.

7. Metodologia

Considerando a natureza tecnológica deste projeto, a metodologia adotada baseia-se na *Design Science Research Methodology* (DSRM), proposta por Peffers *et al.* [8], que fornece um modelo rigoroso de pesquisa voltado à criação de artefatos inovadores para resolver problemas práticos e organizacionais.

- **1. Identificação do problema e motivação:** Constata-se a carência de soluções tecnológicas integradas, tanto para órgãos de segurança quanto para a sociedade civil, que transformem os dados abertos sobre criminalidade em inteligência acionável. A falta de mapeamento adequado dificulta o planejamento de medidas preventivas efetivas.
- **2. Definição dos objetivos de uma solução:** O propósito é o desenvolvimento e a gestão de um *pipeline* analítico, estruturado com algoritmos de Aprendizado de Máquina e amparado por um *dashboard* amigável, capaz de prever ocorrências de roubo e furto de veículos e apresentar manchas criminais.
- **3. Design e Desenvolvimento:** Esta etapa contempla o ciclo de engenharia e ciência de dados inspirado no CRISP-DM (*Cross-Industry Standard Process for Data Mining*). Na primeira iteração do projeto (Sprint 1), desenvolveu-se um *pipeline* automatizado para extração dos microdados criminais do portal da SSP-SP. Na iteração subsequente (Sprint 2 - MVP Analítico), executou-se a fase de pré-processamento, convertendo pares de Latitude/Longitude em hexágonos de alta resolução utilizando o sistema de indexação espacial **Uber H3**. O espaço foi discretizado para transformar a complexidade geográfica em variáveis tabulares. Para estabelecer um marco de referência (*Baseline*), instanciou-se um modelo inicial (Random Forest Classifier) a fim de prever o risco de ocorrência criminal por hexágono, pavimentando o caminho para futuras iterações focadas em Engenharia de Atributos avançada.
- **4. Demonstração e Avaliação:** Consiste na validação do modelo empírico frente aos desafios inerentes à segurança pública. O MVP analítico (*Baseline*) foi avaliado por meio de métricas estatísticas (F1-Score, ROC-AUC) para lidar com a natureza de forte desbalanceamento de classes (ampla maioria de áreas sem crimes). O objetivo desta primeira avaliação não é a precisão absoluta, mas sim constatar a viabilidade preditiva inicial e estabelecer uma linha de base estatística. Este marco será utilizado nas próximas iterações para comprovar o ganho de eficácia gerado pela adição de novas variáveis contextuais e algoritmos otimizados.
- **5. Comunicação:** Os resultados e o conhecimento gerado são compartilhados no âmbito acadêmico e técnico, por meio de documentação e relatórios, destacando a aplicação bem-sucedida das práticas de Planejamento e Gestão de Projetos e ilustrando o ciclo de vida completo de um produto de *software* orientado a dados.

8. Adequação ao Ciclo de Vida CRISP-ML(Q)

O processo de desenvolvimento deste projeto foi estruturado segundo o modelo de referência CRISP-ML(Q) [10], uma extensão do consagrado CRISP-DM voltada especificamente para soluções baseadas em aprendizado de máquina, com ênfase na garantia de qualidade (Q) ao longo de todo o ciclo de vida. A divisão das entregas (Sprints) reflete as fases propostas pela metodologia:

- **Sprint 0 – Compreensão do Negócio e dos Dados (Fase 1 do CRISP-ML(Q)):** Consistiu na definição do problema de segurança pública, no estabelecimento de objetivos mensuráveis e na análise exploratória inicial para atestar a viabilidade da utilização de dados abertos da Secretaria de Segurança Pública.
- **Sprint 1 – Preparação de Dados (Fase 2 do CRISP-ML(Q)):** Envolveu o desenvolvimento de rotinas automatizadas para extração, limpeza e consolidação

dos microdados criminais, além da aplicação de técnicas de geoprocessamento e indexação espacial (H3), visando à estruturação de atributos consumíveis por algoritmos preditivos.

- **Sprint 2 – Engenharia e Avaliação do Modelo (Fases 3 e 4 do CRISP-ML(Q)):** Focou na construção do *baseline* empregando o modelo *Random Forest Classifier*. A validação priorizou métricas adequadas para contextos de desbalanceamento de classes, como F1-Score e ROC-AUC, estabelecendo o limite de qualidade empírico exigido para a aprovação do modelo inicial.
- **Sprint 3 – Implantação do Modelo (Fase 5 do CRISP-ML(Q)):** O modelo treinado foi integrado a uma aplicação web interativa (MVP), encapsulando a complexidade analítica e fornecendo uma interface de usuário (*dashboard*) para a visualização de mapas de calor e estimativas de risco criminal em ambiente de produção em nuvem.

A Fase 6 do CRISP-ML(Q), referente ao Monitoramento e Manutenção contínua do modelo para mitigação de fenômenos como o *concept drift*, excede o escopo delimitado para o MVP atual, restando como recomendação arquitetural para futuras iterações e aprimoramentos do *pipeline*.

9. Arquitetura da Solução e Decisões Técnicas

9.1. Visão geral da arquitetura

A solução foi estruturada como um fluxo sequencial e modular de processamento de dados, no qual cada etapa possui uma responsabilidade bem definida. Em termos lógicos, a arquitetura pode ser representada pelo seguinte encadeamento: **fonte de dados → coleta e pré-processamento → indexação geoespacial → construção dos atributos → modelo preditivo → geração das estimativas de risco → visualização no dashboard**. Essa separação foi adotada para facilitar a manutenção, a reprodutibilidade dos experimentos e a substituição independente de componentes, como o algoritmo de classificação ou a estratégia de criação de atributos, sem exigir a reconstrução de toda a solução.

Os registros de furtos e roubos de veículos constituem a entrada do sistema. Após a coleta, os dados passam por rotinas de limpeza e padronização, responsáveis por remover ou tratar registros inconsistentes e organizar atributos temporais e espaciais em um formato adequado para análise. Em seguida, as coordenadas geográficas são convertidas em identificadores espaciais H3. Os dados processados alimentam o modelo de *Machine Learning*, que produz estimativas de risco por região. Por fim, essas informações são consumidas pela camada de apresentação, responsável por exibir os resultados de forma interativa e espacialmente interpretável.

9.2. Representação geoespacial com H3

Uma das principais decisões de projeto foi não utilizar latitude e longitude brutas como única representação espacial. Coordenadas contínuas dificultam a agregação direta de ocorrências e não representam explicitamente regiões discretas de análise. Por esse motivo, adotou-se o sistema H3, que particiona o território em células hexagonais hierárquicas e associa cada posição geográfica a um identificador espacial [6].

A discretização em hexágonos permite agrupar ocorrências pertencentes a uma mesma área e transformar o problema geográfico em uma estrutura tabular adequada

aos algoritmos de aprendizado de máquina. A escolha também favorece análises de vizinhança e possibilita alterar o nível de resolução espacial conforme a granularidade desejada. Dessa forma, o H3 funciona como elo entre a etapa de geoprocessamento e a etapa preditiva, reduzindo a complexidade de manipulação das coordenadas e mantendo a localização necessária para posterior reconstrução do mapa de risco.

9.3. Modelo preditivo e estratégia de avaliação

O *Random Forest Classifier* foi escolhido como modelo de *baseline* por apresentar características adequadas à primeira versão do artefato: capacidade de capturar relações não lineares, combinação de múltiplas árvores de decisão e menor dependência de transformações complexas dos atributos quando comparado a diversos modelos paramétricos [4]. A finalidade dessa escolha não é assumir que o *Random Forest* representa necessariamente o melhor modelo possível, mas estabelecer uma referência reproduzível contra a qual versões posteriores possam ser comparadas.

Outra decisão técnica importante diz respeito à avaliação. Como a maioria das combinações de região e intervalo temporal pode não possuir ocorrência registrada, o conjunto de dados apresenta tendência ao desbalanceamento entre as classes. Consequentemente, a acurácia isolada poderia mascarar um modelo pouco útil para detectar a classe de interesse. Foram priorizadas, portanto, métricas como *F1-Score* e ROC-AUC, complementando a análise do desempenho preditivo e reduzindo a dependência de uma única medida. Essa decisão está alinhada à literatura sobre avaliação de classificadores em bases desbalanceadas [5].

9.4. Camada de apresentação e aplicação web

A camada de apresentação foi implementada como uma aplicação web em Streamlit. O *framework* executa a lógica da aplicação em um servidor Python e disponibiliza a interface ao usuário por meio do navegador, seguindo uma arquitetura cliente-servidor [7]. Sua adoção foi motivada principalmente pela integração direta com o ecossistema Python utilizado nas etapas de ciência de dados e pela disponibilidade de componentes para tabelas, gráficos, mapas e controles interativos. Com isso, o mesmo ambiente tecnológico pode carregar dados processados, executar a lógica necessária para apresentação dos resultados e renderizar o *dashboard*, reduzindo a complexidade de integração entre um *backend* analítico e uma interface construída em tecnologia distinta.

Para o escopo de um MVP acadêmico, essa decisão privilegia velocidade de desenvolvimento, facilidade de experimentação e simplicidade de implantação. Como contrapartida, uma aplicação concentrada em Streamlit oferece menor desacoplamento entre apresentação e processamento do que uma arquitetura composta por uma API independente e um *frontend* dedicado. Essa limitação foi considerada aceitável nesta etapa, pois o objetivo principal consiste em validar o fluxo completo do artefato e a utilidade das visualizações. Caso requisitos futuros envolvam maior volume de acessos, múltiplos consumidores das predições ou integração com outros sistemas, a camada preditiva poderá ser exposta por uma API própria sem alterar o princípio modular adotado para o *pipeline*.

A versão executável do *dashboard* foi disponibilizada no endereço <https://predicao-furtos-veiculos.streamlit.app/>. A disponibilização do artefato permite demonstrar, de maneira concreta, a integração entre o processamento dos

dados, o modelo preditivo e a visualização espacial, complementando a avaliação estatística com uma demonstração funcional da solução.

9.5. Justificativa das decisões de design

As decisões de design foram orientadas pela necessidade de equilibrar rigor analítico, simplicidade técnica e possibilidade de evolução incremental. A arquitetura em etapas separa aquisição, transformação, modelagem e visualização, favorecendo testes e substituições futuras. O H3 foi empregado para criar uma unidade espacial consistente e reutilizável; o *Random Forest* foi utilizado como referência inicial por sua adequação a relações não lineares e por exigir pouca preparação específica dos atributos; as métricas de avaliação foram escolhidas em função do desbalanceamento esperado; e o Streamlit foi adotado para transformar rapidamente os resultados do *pipeline* em um artefato interativo acessível pelo navegador.

Em conjunto, essas escolhas evitam complexidade arquitetural desnecessária para a fase atual do projeto, sem impedir extensões posteriores. O projeto pode evoluir, por exemplo, por meio da inclusão de novas variáveis contextuais, comparação com outros classificadores, ajuste da resolução H3, persistência dos resultados em banco de dados ou separação da inferência em um serviço independente. Assim, a arquitetura atual deve ser entendida como uma base funcional e extensível, adequada ao objetivo de validar o MVP e estabelecer um ponto de partida técnico para novas iterações.

10. Referências

Referências

- [1] ALVES, L. G. A.; RIBEIRO, H. V.; RODRIGUES, F. A. Crime prediction through urban metrics and statistical learning. **Physica A: Statistical Mechanics and its Applications**, v. 505, p. 435-443, 2018.
- [2] CHAINEY, S.; TOMPSON, L.; UHLIG, S. The utility of hotspot mapping for predicting spatial patterns of crime. **Security Journal**, v. 21, n. 1-2, p. 4-28, 2008.
- [3] MOHLER, G. O.; SHORT, M. B.; MALINOWSKI, S.; JOHNSON, M.; TITA, G. E.; BERTOZZI, A. L.; BRANTINGHAM, P. J. Randomized controlled field trials of predictive policing. **Journal of the American Statistical Association**, v. 110, n. 512, p. 1399–1411, 2015.
- [4] BREIMAN, L. Random forests. **Machine Learning**, v. 45, p. 5–32, 2001.
- [5] SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. **PLOS ONE**, v. 10, n. 3, e0118432, 2015.
- [6] UBER TECHNOLOGIES. **H3: Hexagonal hierarchical geospatial indexing system**. Disponível em: <https://h3geo.org/>. Acesso em: 6 out. 2026.
- [7] STREAMLIT. **Streamlit documentation: Understanding Streamlit's client-server architecture**. Disponível em: <https://docs.streamlit.io/develop/concepts/architecture/architecture>. Acesso em: 6 out. 2026.
- [8] PEFFERS, K.; TUUNANEN, T.; ROTHENBERGER, M. A.; CHATTERJEE, S. A design science research methodology for information systems research. **Journal of Management Information Systems**, v. 24, n. 3, p. 45-77, 2007.

- [9] PERRY, W. L.; MCINNIS, B.; PRICE, C. C.; SMITH, S. C.; HOLLYWOOD, J. S. **Predictive policing: The role of crime forecasting in law enforcement operations.** Santa Monica: Rand Corporation, 2013.
- [10] STUDER, S. *et al.* Towards CRISP-ML(Q): A machine learning systems engineering process with quality assurance methodology. **Procedia Computer Science**, v. 184, p. 392-399, 2021.